

Agentes Autônomos - Análise de CSV

Introdução

Este relatório descreve uma solução de Recuperação de Informação Aumentada por Geração (RAG) para análise de dados em formato CSV, especificamente notas fiscais. A solução utiliza tecnologias de ponta em processamento de linguagem natural e recuperação de informação para fornecer respostas precisas e contextualizadas a perguntas dos usuários.

Framework Utilizado

O projeto foi desenvolvido utilizando a arquitetura **RAG (Retrieval-Augmented Generation)**, que combina modelos de linguagem (LLMs) com bases de dados vetoriais para recuperação de informações. As principais ferramentas e bibliotecas utilizadas foram:

- **LangChain:** Um framework para construir aplicações com modelos de linguagem, facilitando a integração de diferentes componentes como retrievers e modelos de linguagem.
- **FAISS:** Uma biblioteca para busca eficiente de similaridade em grandes conjuntos de vetores, usada para armazenar e recuperar embeddings de texto.
- **HuggingFace Embeddings:** Modelos de embedding pré-treinados, neste caso, o modelo multilingual-e5-large, para transformar texto em vetores numéricos.
- **OpenAI:** Fornece o modelo de linguagem GPT-4o-mini, usado para gerar respostas com base no contexto recuperado.
- **Pandas:** Manipulação de dados CSV.
- **PDFPlumber e python-pptx:** Leitura de PDFs e apresentações PPTX.
- **Google Colab:** Ambiente para execução e desenvolvimento.
- **Transformers e Torch:** Suporte aos modelos de linguagem.

Funcionamento da Solução

O agente autônomo foi projetado para responder perguntas sobre dados de diferentes formatos, incluindo arquivos CSV, PDF, TXT e PPTX. O fluxo de funcionamento é o seguinte:

1. **Ingestão dos Dados:**

O agente lê arquivos presentes em um diretório, processando CSVs, PDFs, apresentações PPTX e arquivos TXT.

2. **Chunking:**

Os documentos são divididos em pequenos trechos (chunks) de até 300 caracteres

com sobreposição de 50, para melhorar a precisão na busca de informações.

3. **Vetorização:** Cada chunk é convertido em vetor utilizando embeddings do modelo `intfloat/multilingual-e5-large`.
4. **Armazenamento:** Os vetores são armazenados em um índice FAISS, permitindo recuperação rápida e precisa.
5. **RAG Pipeline:** Ao receber uma pergunta, o agente consulta os vetores, recupera os chunks mais relevantes e envia juntamente com a pergunta para o modelo GPT-4o-mini, que gera uma resposta contextualizada citando as fontes.
6. **Recuperação de Contexto:** Quando uma pergunta é feita, o retriever busca os 5 chunks mais relevantes no Vector Store.
7. **Geração de Resposta:** Os chunks recuperados são formatados e passados para o modelo GPT-4o-mini junto com a pergunta, que gera uma resposta contextualizada

Testes Executados e Resultados

Foram executadas quatro perguntas para validação da solução:

Pergunta 1: Do que se trata meus dados?

Resultado:

Os dados que você forneceu parecem consistir em informações sobre notas fiscais relacionadas a contratos ou transações entre órgãos do governo e empresas prestadoras de serviços. Cada entrada contém detalhes como:

1. Órgão governamental (por exemplo, Ministérios da Educação, Saúde, Defesa).
2. Instituição ou empresa beneficiária (como Universidades Federais e a Fundação Oswaldo Cruz).
3. CNPJ (Cadastro Nacional da Pessoa Jurídica) tanto do órgão quanto da empresa fornecedora.
4. Nome da empresa fornecedora

Essas informações são comuns em registros financeiros e podem ser utilizadas para fins de auditoria, controle e transparência nas despesas públicas. (Fonte: notas-fiscais (4).csv)

Pergunta 2: Qual é o valor total das notas fiscais em reais

Resultado:

O valor total das notas fiscais é: R\$ 315.715.534,89

Pergunta 3: Liste cinco fornecedores presente nos dados

Resultado:

Os fornecedores presentes nos dados são:

1. SUPPLY VITAL LTDA - CNPJ: 37.539.851/0001-17
2. SUL CASCOL COMBUSTIVEIS PARA VEICULOS LTDA
3. PARANOIA 1 - CASCOL COMBUSTIVEIS PARA VEICULOS LTDA
4. MECANICA UNIAO PECAS E SERVICOS LTDA
5. DAISY SANTOS LIMA

(Fonte: notas-fiscais (4).csv)

Pergunta 4: Liste cinco órgãos destinatários presentes nos dados

Resultado:

Os órgãos destinatários presentes nos dados são:

1. Ministério da Educação
2. Universidade Federal do Rio de Janeiro
3. Ministério da Saúde
4. Fundação Oswaldo Cruz
5. Ministério dos Direitos Humanos e Cidadania - Unidades com vínculo direto

(Fonte: notas-fiscais (4).csv)

Repositórios e Links



GitHub:

<https://github.com/leogiarola/l2A2/tree/f33a44a50b9b695b7d9bf769d3b340311db33093/Modulo%202/Atividades>

Conclusão

A solução apresentada demonstra a eficácia de combinar técnicas de recuperação de informação e geração de linguagem para analisar e responder perguntas sobre dados em formato CSV. Com a capacidade de processar múltiplos formatos de documentos e fornecer respostas contextualizadas, esta abordagem pode ser amplamente aplicada em cenários de análise de dados e suporte ao usuário.